Домашние задание №2

In [2]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
plt.rcParams.update({'font.size': 14})
```

In [3]:

```
def calc_mse(y, y_pred):
    err = np.mean((y - y_pred)**2)
    return err
```

In [4]:

```

X = np.array([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1],
              [1, 1, 2, 1, 3, 0, 5, 10, 1, 2],  # стаж
              [500, 700, 750, 600, 1450,        # средняя стоимость занятия
               800, 1500, 2000, 450, 1000],
              [1, 1, 2, 1, 2, 1, 3, 3, 1, 2]])  # квалификация репетитора

y = [45, 55, 50, 59, 65, 35, 75, 80, 50, 60]    # средний балл ЕГЭ (целевая переменная)
n = X.shape[1]
```

1. Постройте график зависимости весов всех признаков от lambda в L2-регуляризации (на данных из урока).

In [5]:

```
# Стандартизируем признаки
X_st = X.copy()
X_st = X_st.astype(np.float64)

for i in range(1, 4):
    X_st[i] = (X_st[i] - X_st[i].mean()) / X_st[i].std()

# Напишем функцию градиентного спуска с L2 решуляризацией
def eval_model_reg2(X, y, iterations, lambda_, alpha=1e-4):
    np.random.seed(42)
    W = np.random.randn(X.shape[0])
    n = X.shape[1]
    for i in range(1, iterations + 1):
        y_pred = np.dot(W, X)
        err = calc_mse(y, y_pred)
        W -= alpha * (1/n * 2 * np.dot((y_pred - y), X.T) + 2 * lambda_ * W)
    return W
```

In [6]:

```
# Получим коэффициенты при разных lambda
W_all = []
for i in (1, 0.1, 0.005, 0.0001):
    W_all.append(list(eval_model_reg2(X_st, y, iterations=1000, alpha=1e-3, lambda_= i)

W_all_2 = pd.DataFrame(W_all, columns = ("w_0", "w_1", "w_2", "w_3"))
```

In [7]:

```
# Нарисуем график зависимости весов всех признаков от lambda в L2-регуляризации (на дан
plt.style.use('fivethirtyeight')
plt.figure(figsize=(10, 7))
color = ["g","r","y","b"]
label = ["lambda_ = 1", "lambda_ = 0.1,", "lambda_ = 0.005", "lambda_ = 0.0001"]
for i in range(4):
    plt.plot(W_all_2.loc[i], color = color[i], label=label[i])
    plt.xlabel('Вес')
    plt.ylabel('Значение веса')
    plt.title("График зависимости весов всех признаков от lambda в L2-регуляризации")
    plt.legend()
```

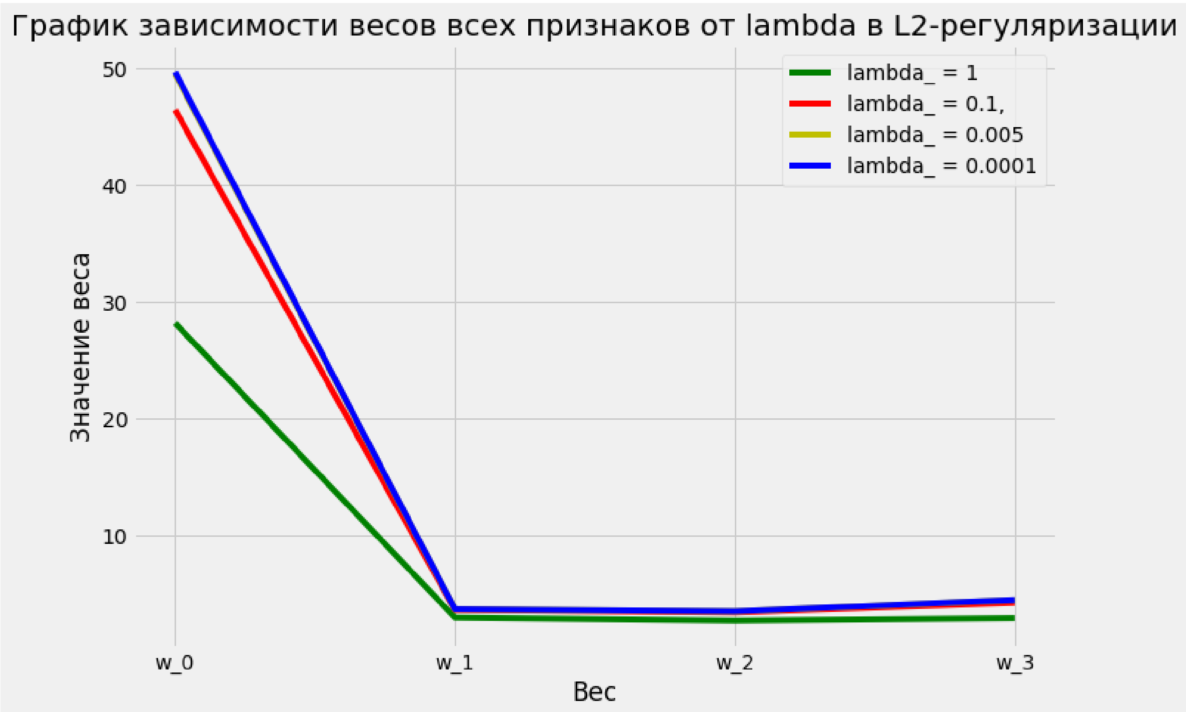

2. Можно ли к одному и тому же признаку применить сразу и нормализацию, и стандартизацию?

In [8]:

```
n = X.shape[1]
X = np.array([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1],
              [1, 1, 2, 1, 3, 0, 5, 10, 1, 2],  # стаж
              [500, 700, 750, 600, 1450,        # средняя стоимость занятия
               800, 1500, 2000, 450, 1000]])

y = [45, 55, 50, 59, 65, 35, 75, 80, 50, 60]    # средний балл ЕГЭ (целевая переменная)
```

Посмотрим на коэффициенты и MSE до масштабирования

In [9]:

```
w = np.linalg.inv(X @ X.T) @ X @ y
w
```

Out[9]:

```
array([4.25569284e+01, 2.62631471e+00, 8.22015726e-03])
```

In [10]:

```
y_pred = np.dot(w, X)
calc_mse(y, y_pred)
```

Out[10]:

```
42.983380986418894
```

Попробуем последовательно применить стачало нормализацию, а затем стандатризацию. Потом, наоборот и посмотрим, что будет происходить с данными, коэффициенами и ошибкой обучения.

Проведем нормализацию исходных признаков

In [11]:

```
X_norm = X.copy()
X_norm = X_norm.astype(np.float64)
X_norm
```

Out[11]:

```
array([[1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00,
        1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00],
       [1.00e+00, 1.00e+00, 2.00e+00, 1.00e+00, 3.00e+00, 0.00e+00,
        5.00e+00, 1.00e+01, 1.00e+00, 2.00e+00],
       [5.00e+02, 7.00e+02, 7.50e+02, 6.00e+02, 1.45e+03, 8.00e+02,
        1.50e+03, 2.00e+03, 4.50e+02, 1.00e+03]])
```

In [12]:

```
X_norm[1] = (X_norm[1] - X_norm[1].min()) / (X_norm[1].max() - X_norm[1].min())
X_norm[1]
```

Out[12]:

```
array([0.1, 0.1, 0.2, 0.1, 0.3, 0. , 0.5, 1. , 0.1, 0.2])
```

In [13]:

```
X_norm[2] = (X[2] - X[2].min()) / (X[2].max() - X[2].min())
X_norm[2]
```

Out[13]:

```
array([0.03225806, 0.16129032, 0.19354839, 0.09677419, 0.64516129,
       0.22580645, 0.67741935, 1.        , 0.        , 0.35483871])
```

In [14]:

```
X_norm[2] = (X_norm[2] - X_norm[2].min()) / (X_norm[2].max() - X_norm[2].min())
X_norm[2]
```

Out[14]:

```
array([0.03225806, 0.16129032, 0.19354839, 0.09677419, 0.64516129,
       0.22580645, 0.67741935, 1.        , 0.        , 0.35483871])
```

In [15]:

```
X_norm[1] = (X_norm[1] - X_norm[1].min()) / (X_norm[1].max() - X_norm[1].min())
X_norm[1]
```

Out[15]:

```
array([0.1, 0.1, 0.2, 0.1, 0.3, 0. , 0.5, 1. , 0.1, 0.2])
```

In [16]:

```
w_norm = np.linalg.inv(X_norm @ X_norm.T) @ X_norm @ y
print(f"Коэффициенты после нормализаци исходных признаков: {w_norm}")
y_pred = np.dot(w_norm, X_norm)
print(f"MSE после нормализаци исходных признаков: {calc_mse(y, y_pred)}")
```

```
Коэффициенты после нормализаци исходных признаков: [46.25599918 26.26314715 1
2.74124375]
MSE после нормализаци исходных признаков: 42.98338098641885
```

Проведем стандартизацию нормализованнных признаков

In [17]:

```
X_norm_st = X_norm.copy().astype(np.float64)
X_norm_st[1] = (X_norm_st[1] - X_norm_st[1].mean()) / X_norm_st[1].std()
X_norm_st[1]
```

Out[17]:

```
array([-0.57142857, -0.57142857, -0.21428571, -0.57142857,  0.14285714,
       -0.92857143,  0.85714286,  2.64285714, -0.57142857, -0.21428571])
```

In [18]:

```
X_norm_st[2] = (X_norm_st[2] - X_norm_st[2].mean()) / X_norm_st[2].std()
X_norm_st[2]
```

Out[18]:

```
array([-0.97958969, -0.56713087, -0.46401617, -0.77336028,  0.97958969,
       -0.36090146,  1.08270439,  2.11385144, -1.08270439,  0.05155735])
```

In [19]:

```
w_norm_st = np.linalg.inv(X_norm_st @ X_norm_st.T) @ X_norm_st @ y
print(f"Коэффициенты после стандартизации нормализованнных признаков: {w_norm_st}")
y_pred = np.dot(w_norm_st, X_norm_st)
print(f"MSE после стандартизации нормализованнных признаков: {calc_mse(y, y_pred)}")
```

```
Коэффициенты после стандартизации нормализованнных признаков: [57.4
7.3536812   3.98592874]
MSE после стандартизации нормализованнных признаков: 42.98338098641888
```

Теперь проведем масштабирование в обратном порядке

Проведем стандартизацию исходных признаков

In [20]:

```
X_st = X.copy()
X_st = X_st.astype(np.float64)
X_st
```

Out[20]:

```
array([[1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00,
        1.00e+00, 1.00e+00, 1.00e+00, 1.00e+00],
       [1.00e+00, 1.00e+00, 2.00e+00, 1.00e+00, 3.00e+00, 0.00e+00,
        5.00e+00, 1.00e+01, 1.00e+00, 2.00e+00],
       [5.00e+02, 7.00e+02, 7.50e+02, 6.00e+02, 1.45e+03, 8.00e+02,
        1.50e+03, 2.00e+03, 4.50e+02, 1.00e+03]])
```

In [21]:

```
X_st[1] = (X_st[1] - X_st[1].mean()) / X_st[1].std()
X_st[1]
```

Out[21]:

```
array([-0.57142857, -0.57142857, -0.21428571, -0.57142857,  0.14285714,
       -0.92857143,  0.85714286,  2.64285714, -0.57142857, -0.21428571])
```

In [22]:

```
X_st[2] = (X_st[2] - X_st[2].mean()) / X_st[2].std()
X_st[2]
```

Out[22]:

```
array([-0.97958969, -0.56713087, -0.46401617, -0.77336028,  0.97958969,
       -0.36090146,  1.08270439,  2.11385144, -1.08270439,  0.05155735])
```

In [23]:

```
w_st = np.linalg.inv(X_st @ X_st.T) @ X_st @ y
print(f"Коэффициенты после стандартизацию исходных признаков: {w_st}")
y_pred = np.dot(w_st, X_st)
print(f"MSE после w_norm_st: {calc_mse(y, y_pred)}")
```

```
Коэффициенты после стандартизацию исходных признаков: [57.4         7.3536812
3.98592874]
MSE после w_norm_st: 42.98338098641888
```

Проведем нормализацию стандартизированных признаков

In [24]:

```
X_st_norm = X_st.copy()
X_st_norm
```

Out[24]:

```
array([[ 1.        ,  1.        ,  1.        ,  1.        ,  1.        ,
         1.        ,  1.        ,  1.        ,  1.        ,  1.        ],
       [-0.57142857, -0.57142857, -0.21428571, -0.57142857,  0.14285714,
        -0.92857143,  0.85714286,  2.64285714, -0.57142857, -0.21428571],
       [-0.97958969, -0.56713087, -0.46401617, -0.77336028,  0.97958969,
        -0.36090146,  1.08270439,  2.11385144, -1.08270439,  0.05155735]])
```

In [25]:

```
X_st_norm[1] = (X_st_norm[1] - X_st_norm[1].min()) / (X_st_norm[1].max() - X_st_norm[1]
X_st_norm[1]
```

Out[25]:

```
array([0.1, 0.1, 0.2, 0.1, 0.3, 0. , 0.5, 1. , 0.1, 0.2])
```

In [26]:

```
X_st_norm[2] = (X_st_norm[2] - X_st_norm[2].min()) / (X_st_norm[2].max() - X_st_norm[2]
X_st_norm[2]
```

Out[26]:

```
array([0.03225806, 0.16129032, 0.19354839, 0.09677419, 0.64516129,
       0.22580645, 0.67741935, 1.        , 0.        , 0.35483871])
```

In [27]:

```
w_st_norm = np.linalg.inv(X_st_norm @ X_st_norm.T) @ X_st_norm @ y
print(f"Коэффициенты после нормализации стандартизированных признаков: {w_st_norm}")
y_pred = np.dot(w_st_norm, X_st_norm)
print(f"MSE после нормализации стандартизированных признаков: {calc_mse(y, y_pred)}")
```

```
Коэффициенты после нормализации стандартизированных признаков: [46.25599918 2
6.26314715 12.74124375]
MSE после нормализации стандартизированных признаков: 42.98338098641885
```

Сравним коэффициенты при разных комбинациях масштабирования

In [28]:

```
print(f"Коэффициенты после нормализаци исходных признаков: {w_norm}")
print(f"Коэффициенты после нормализации стандартизированных признаков: {w_st_norm}")
print(f"Коэффициенты после стандартизацию исходных признаков: {w_st}")
print(f"Коэффициенты после стандартизации нормализованнных признаков: {w_norm_st}")
```

```
Коэффициенты после нормализаци исходных признаков: [46.25599918 26.26314715 1
2.74124375]
Коэффициенты после нормализации стандартизированных признаков: [46.25599918 2
6.26314715 12.74124375]
Коэффициенты после стандартизацию исходных признаков: [57.4         7.3536812
3.98592874]
Коэффициенты после стандартизации нормализованнных признаков: [57.4
7.3536812   3.98592874]
```

Сравним признаки при разных комбинациях масштабирования

In [29]:

```
print(X_norm[2])
print(X_st_norm[2])
print(X_norm_st[2])
print(X_st[2])
```

```
[0.03225806 0.16129032 0.19354839 0.09677419 0.64516129 0.22580645
 0.67741935 1.         0.         0.35483871]
[0.03225806 0.16129032 0.19354839 0.09677419 0.64516129 0.22580645
 0.67741935 1.         0.         0.35483871]
[-0.97958969 -0.56713087 -0.46401617 -0.77336028  0.97958969 -0.36090146
  1.08270439  2.11385144 -1.08270439  0.05155735]
[-0.97958969 -0.56713087 -0.46401617 -0.77336028  0.97958969 -0.36090146
  1.08270439  2.11385144 -1.08270439  0.05155735]
```

Вывод

Смысла в одновременом применении нормализации и стандартизации нет, так как после нормализации стандартизированных признаков мы получаем те же признаки, что и после нормализации исходных признаков. Тот же принцип действует и в обратном случае. После стандартизации нормализизированных призаков, мы получаем теже признаки, что и после стандартизации исходных. Поэтому нужно просто применять либо нормализацию либо стандартизацию.

3. *Напишите функцию наподобие eval_model_reg2, но для применения L1-регуляризации.

In [186]:

```
n = X.shape[1]
X = np.array([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1],
              [1, 1, 2, 1, 3, 0, 5, 10, 1, 2],  # стаж
              [500, 700, 750, 600, 1450,        # средняя стоимость занятия
               800, 1500, 2000, 450, 1000],
              [1, 1, 2, 1, 2, 1, 3, 3, 1, 2]])  # квалификация репетитора

y = [45, 55, 50, 59, 65, 35, 75, 80, 50, 60]    # средний балл ЕГЭ (целевая переменная
```

In [187]:

```
# Стандартизируем признаки
X_st = X.copy()
X_st = X_st.astype(np.float64)

for i in range(1, 4):
    X_st[i] = (X_st[i] - X_st[i].mean()) / X_st[i].std()

# Напишем функцию градиентного спуска с L1 регуляризацией
def eval_model_reg1(X, y, iterations, lambda_, alpha=1e-4):
    np.random.seed(42)
    W = np.random.randn(X.shape[0])
    n = X.shape[1]
    for i in range(1, iterations + 1):
        y_pred = np.dot(W, X)
        err = calc_mse(y, y_pred)
        W -= alpha * (1/n * 2 * np.dot((y_pred - y), X.T) + lambda_ * np.sign(W))
    return W
```

In [188]:

```
# Посчитаем коэффициенты
w_L1 = eval_model_reg1(X_st, y, iterations=10000, alpha=1e-3, lambda_= 0.001)
```

In [189]:

```
# Посчитаем MSE
y_pred = np.dot(w_L1, X_st)
calc_mse(y, y_pred)
```

Out[189]:

```
39.80711256982036
```

4. *Сравните на графиках изменение весов признаков от lambda в L1-регуляризации и L2-регуляризации (на данных из урока).

In [208]:

```
n = X.shape[1]
X = np.array([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1],
              [1, 1, 2, 1, 3, 0, 5, 10, 1, 2],   # стаж
              [500, 700, 750, 600, 1450,         # средняя стоимость занятия
               800, 1500, 2000, 450, 1000],
              [1, 1, 2, 1, 2, 1, 3, 3, 1, 2]])  # квалификация репетитора

y = [45, 55, 50, 59, 65, 35, 75, 80, 50, 60]    # средний балл ЕГЭ (целевая переменная,
```

In [209]:

```
# Стандартизируем признаки
X_st = X.copy()
X_st = X_st.astype(np.float64)

for i in range(1, 4):
    X_st[i] = (X_st[i] - X_st[i].mean()) / X_st[i].std()
```

In [210]:

```
# Получим коэффициенты при разных lambda
W_all = []
for i in (1, 0.1, 0.005, 0.0001):
    W_all.append(list(eval_model_reg1(X_st, y, iterations=1000, alpha=1e-3, lambda_= i)

W_all_1 = pd.DataFrame(W_all, columns = ("w_0", "w_1", "w_2", "w_3"))
```

In [211]:

```
# Получим коэффициенты при разных lambda
W_all = []
for i in (1, 0.1, 0.005, 0.0001):
    W_all.append(list(eval_model_reg2(X_st, y, iterations=1000, alpha=1e-3, lambda_= i)

W_all_2 = pd.DataFrame(W_all, columns = ("w_0", "w_1", "w_2", "w_3"))
```

In [214]:

```
W_all_1[["w_1", "w_2", "w_3"]]
```

Out[214]:

	w_1	w_2	w_3
0	3.490986	3.303796	4.272869
1	3.647092	3.463727	4.442508
2	3.663570	3.480608	4.460414
3	3.664420	3.481479	4.461338

In [221]:

```
# Нарисуем график зависимости весов всех признаков от lambda в L1-регуляризации (на дан
plt.style.use('fivethirtyeight')
plt.figure(figsize=(6, 4))
color = ["g","r","y","b"]
label = ["lambda_ = 1", "lambda_ = 0.1,", "lambda_ = 0.005", "lambda_ = 0.0001"]
for i in range(4):
    plt.plot(W_all_1.loc[i], color = color[i], label=label[i])
    plt.xlabel('Вес')
    plt.ylabel('Значение веса')
    plt.title("График зависимости весов всех признаков от lambda в L1-регуляризации")
    plt.legend()
```

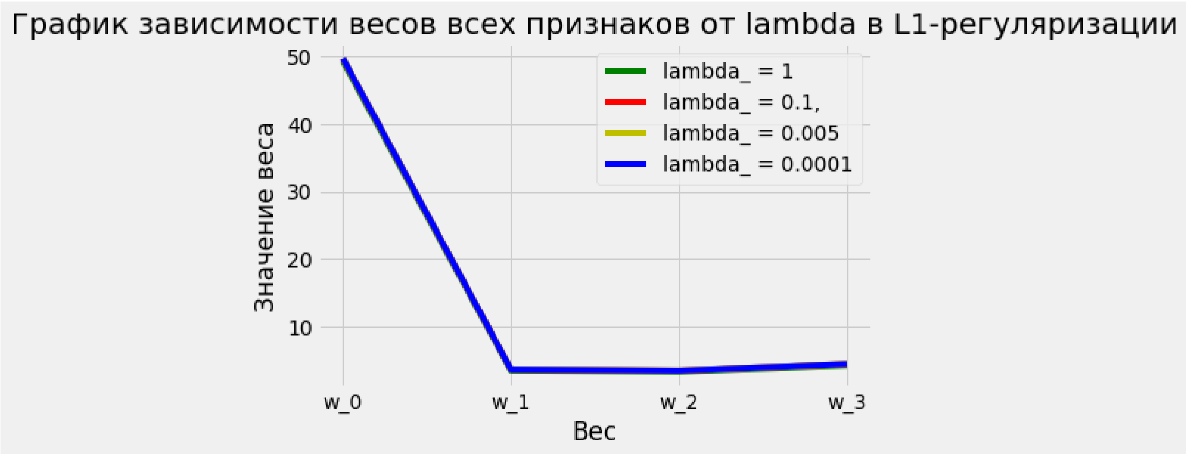

In [216]:

```
# Нарисуем график зависимости весов всех признаков от lambda в L2-регуляризации (на дан
plt.style.use('fivethirtyeight')
plt.figure(figsize=(6, 4))
color = ["g","r","y","b"]
label = ["lambda_ = 1", "lambda_ = 0.1,", "lambda_ = 0.005", "lambda_ = 0.0001"]
for i in range(4):
    plt.plot(W_all_2.loc[i], color = color[i], label=label[i])
    plt.xlabel('Вес')
    plt.ylabel('Значение веса')
    plt.title("График зависимости весов всех признаков от lambda в L2-регуляризации")
    plt.legend()
```

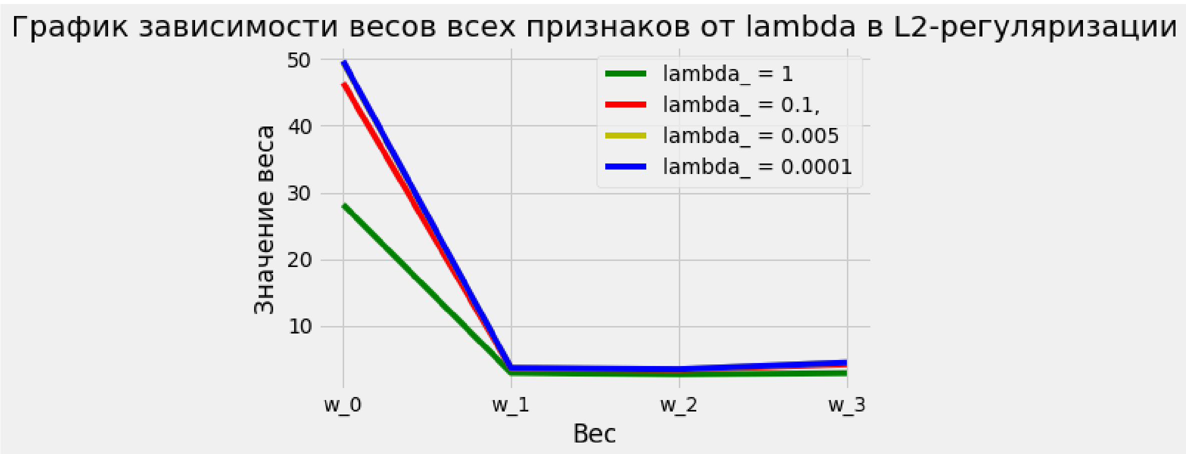

Вывод:

На существующем наборе данных мы не видим существенного отличия на графиках изменение весов признаков от lambda в L1-регуляризаци, как это наблюдается при L2 регуляризации.

5. *Постройте графики зависимости весов двух признаков (стаж и стоимость занятия) от количества итераций для градиентного спуска и для стохастического градиентного спуска (на данных из урока).

In [117]:

```
n = X.shape[1]
X = np.array([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1],
              [1, 1, 2, 1, 3, 0, 5, 10, 1, 2],  # стаж
              [500, 700, 750, 600, 1450,        # средняя стоимость занятия
               800, 1500, 2000, 450, 1000]])

y = [45, 55, 50, 59, 65, 35, 75, 80, 50, 60]    # средний балл ЕГЭ (целевая переменная)
```

In [61]:

```
# Стандартизируем признаки
X_st = X.copy()
X_st = X_st.astype(np.float64)

for i in range(1, 3):
    X_st[i] = (X_st[i] - X_st[i].mean()) / X_st[i].std()
```

In [62]:

```
def eval_model_GD(X, y, iterations, lambda_, alpha=1e-4):
    W_all_GD = []
    np.random.seed(42)
    W = np.random.randn(X.shape[0])
    n = X.shape[1]
    for i in range(iterations + 1):
        y_pred = np.dot(W, X)
        err = calc_mse(y, y_pred)
        W -= (alpha * 1/n * 2 * np.dot(X, (np.dot(W, X) - y)))
        W_all_GD.append(list(W[[1, 2]]))
    return W_all_GD
```

In [63]:

```python
# Метод стохастического градиентного спуска (mini-batch SGD)
def eval_model_SGD(X, y, iterations, qty_in_batch, alpha=1e-4):
    np.random.seed(42)
    W_all_SGD = []
    W = np.random.randn(X.shape[0]) # начальное приближение весов
    n = X.shape[1] # число наблюдений
    n_batch = n // qty_in_batch
    if n % qty_in_batch != 0:
        n_batch += 1
    for i in range(1, iterations + 1):
        for b in range(n_batch):
            start_ = qty_in_batch * b
            end_ = qty_in_batch * (b + 1)
            X_tmp = X[:, start_ : end_]
            y_tmp = y[start_ : end_]
            y_pred_tmp = np.dot(W, X_tmp)
            err = calc_mse(y_tmp, y_pred_tmp)
            W -= alpha * (1/n * 2 * np.dot((y_pred_tmp - y_tmp), X_tmp.T))
            W_all_SGD.append(list(W[[1, 2]]))
    return W_all_SGD
```

In [149]:

```
def mserror(X, w, y_pred):
    y = X.T.dot(w)
    return (sum((y - y_pred)**2)) / len(y)
# инициализируем начальный вектор весов
w = np.zeros(X.shape[0])
# список векторов весов после каждой итерации
w_list = []
# список значений ошибок после каждой итерации
errors = []
# шаг градиентного спуска
eta = 5e-2
# максимальное число итераций
max_iter = 1e6
# критерий сходимости (разница весов, при которой алгоритм останавливается)
min_weight_dist = 1e-4
# зададим начальную разницу весов большим числом
weight_dist = np.inf
# счетчик итераций
iter_num = 0
np.random.seed(1234)
W_all_SGD_2 = []
# ход градиентного спуска
while weight_dist > min_weight_dist and iter_num < max_iter:
    # генерируем случайный индекс объекта выборки
    train_ind = np.random.randint(X.shape[1])
    new_w = w - 2 * eta * np.dot(X_st[:,train_ind], (np.dot(X_st[:,train_ind], w) - y[t
    weight_dist = np.linalg.norm(new_w - w, ord=2)
    w_list.append(new_w.copy())
    errors.append(mserror(X_st, new_w, y))
    iter_num += 1
    w = new_w
#     if iter_num % 50 == 0:
    W_all_SGD_2.append(list(w[[1, 2]]))

w_list = np.array(w_list)
print(f'В случае использования стохастического градиентного спуска функционал ошибки сс
print(f'Количество итераций - {iter_num}')
```

```
В случае использования стохастического градиентного спуска функционал ошибки
составляет 44.4301
Количество итераций - 5289
```

In [143]:

```
# Получим коэффициенты для градиентого спуска на разных итерациях
W_all_GD = eval_model_GD(X_st, y, iterations=5000, alpha=1e-3, lambda_= 0.001)
W_all_GD = pd.DataFrame(W_all_GD, columns = ("w_1", "w_2"))
```

In [144]:

```
# Получим коэффициенты для стохастического градиентого спуска с батчами на разных итерс
W_all_SGD = eval_model_SGD(X_st, y, iterations=5000, qty_in_batch = 2, alpha=1e-3)
W_all_SGD = pd.DataFrame(W_all_SGD, columns = ("w_1", "w_2"))
```

In [155]:

```
# Получим коэффициенты для классического стохастического градиентого спуска на разных и
W_all_SGD_2 = pd.DataFrame(W_all_SGD_2, columns = ("w_1", "w_2"))
```

In [145]:

```
# Построим график для градиентого спуска на разных итерациях
plt.style.use('fivethirtyeight');
plt.figure(figsize=(6, 4));
W_all_GD.plot();
plt.xlabel('Номер итерации');
plt.ylabel('Значение веса');
plt.title("График зависимости весов от количества итераций для градиентного спуска");
```

```
<Figure size 432x288 with 0 Axes>
```

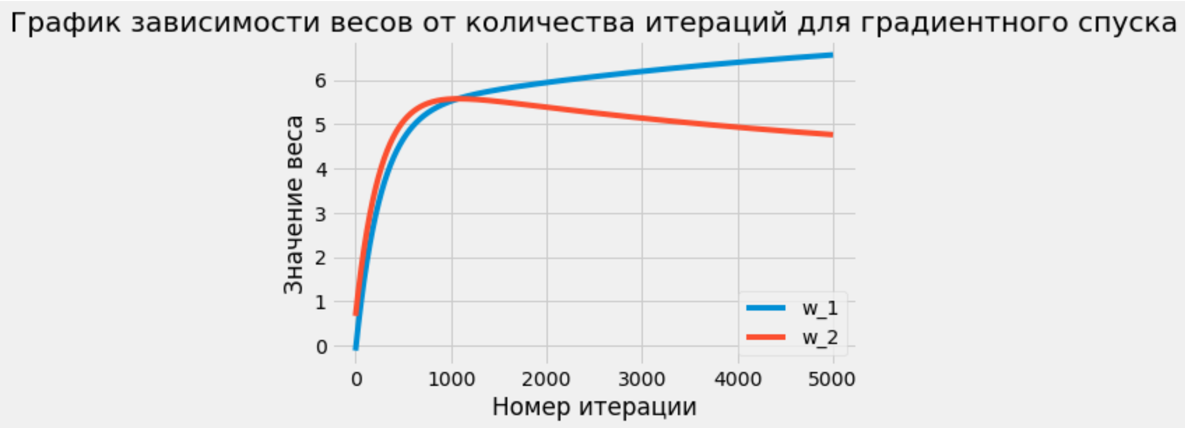

In [156]:

```
# Построим график для стохастического градиентого спуска с батчами на разных итерациях
W_all_SGD.loc[:50].plot();
plt.xlabel('Номер итерации')
plt.ylabel('Значение веса')
plt.title("График зависимости весов от количества итераций для стохастического градиент
```

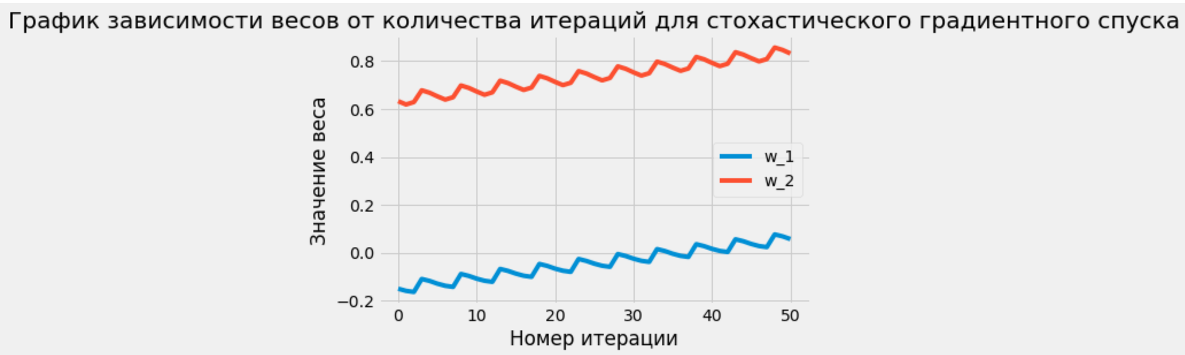

In [162]:

```
# Построим график для классическтго стохастического градиентого спуска на разных итерац
W_all_SGD_2[["w_1", "w_2"]][:100].plot();
plt.xlabel('Номер итерации')
plt.ylabel('Значение веса')
plt.title("График зависимости весов от количества итераций для классического стохастиче
```

График зависимости весов от количества итераций для классического стохастического градиентного спуска

Вывод:

Видим, что при стохастическом градиентном спуске изменения весов носят неровный характер, в отличие от простого градиетого спуска