Домашнее задание

1. В коде из методички реализуйте один или несколько критериев останова (количество листьев, количество используемых признаков, глубина дерева и т.д.).

Сгенерируем данные

In [2]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
# Сгенерируем данные
from sklearn import datasets
from matplotlib.colors import ListedColormap

# сгеренируем данные с помощью sklearn.datasets
classes = datasets.make_classification(n_samples=500, n_features=2, n_informative=2,
                                       n_redundant=0, n_classes=2, random_state=6)
# datasets.make_blobs(centers = 5, cluster_std = 1, random_state=1)

# и изобразим их на графике
colors = ListedColormap(['red', 'blue'])
light_colors = ListedColormap(['lightcoral', 'lightblue'])

plt.figure(figsize=(8, 8))
plt.scatter([x[0] for x in classes[0]], [x[1] for x in classes[0]], c=classes[1], cmap=
```

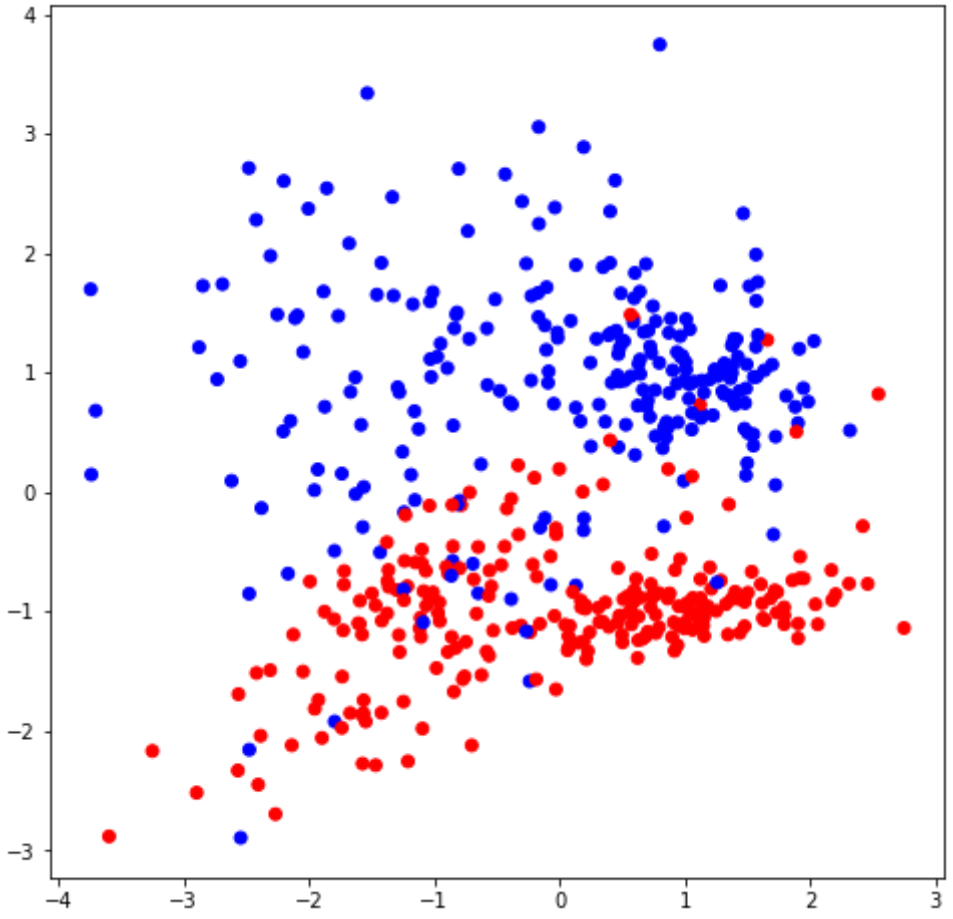

Далее разделим выборку на обучающую и тестовую.

In [3]:

```
# перемешивание датасета
np.random.seed(41)
shuffle_index = np.random.permutation(classes[0].shape[0])
X_shuffled, y_shuffled = classes[0][shuffle_index], classes[1][shuffle_index]

# разбивка на обучающую и тестовую выборки
train_proportion = 0.7
train_test_cut = int(len(classes[0]) * train_proportion)

train_data, test_data, train_labels, test_labels = \
    X_shuffled[:train_test_cut], \
    X_shuffled[train_test_cut:], \
    y_shuffled[:train_test_cut], \
    y_shuffled[train_test_cut:]
```

In [4]:

```
# Реализуем класс узла

class Node:

    def __init__(self, index, t, true_branch, false_branch):
        self.index = index  # индекс признака, по которому ведется сравнение с порогом
        self.t = t  # значение порога
        self.true_branch = true_branch  # поддерево, удовлетворяющее условию в узле
        self.false_branch = false_branch  # поддерево, не удовлетворяющее условию в узл
```

In [5]:

```
# И класс терминального узла (листа)

class Leaf:

    def __init__(self, data, labels):
        self.data = data
        self.labels = labels
        self.prediction = self.predict()

    def predict(self):
        # подсчет количества объектов разных классов
        classes = {}  # сформируем словарь "класс: количество объектов"
        for label in self.labels:
            if label not in classes:
                classes[label] = 0
            classes[label] += 1
        #  найдем класс, количество объектов которого будет максимальным в этом листе и
        prediction = max(classes, key=classes.get)
        return prediction
```

Индекс Джини:

$$H(X) = 1 - \sum_{k=1}^{K} p_k^2.$$

In [6]:

```python
# Расчет критерия Джини

def gini(labels):
    #  подсчет количества объектов разных классов
    classes = {}
    for label in labels:
        if label not in classes:
            classes[label] = 0
        classes[label] += 1

    #  расчет критерия
    impurity = 1 # коэффициент неопределенности Джини
    for label in classes:
        p = classes[label] / len(labels)
        impurity -= p ** 2

    return impurity
```

Функционал качества:

$$Q = H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r)$$

In [7]:

```python
# Расчет качества

def quality(left_labels, right_labels, current_gini):

    # доля выбоки, ушедшая в левое поддерево
    p = float(left_labels.shape[0]) / (left_labels.shape[0] + right_labels.shape[0])

    return current_gini - p * gini(left_labels) - (1 - p) * gini(right_labels)
```

In [8]:

```python
# Разбиение датасета в узле

def split(data, labels, index, t):
    left = np.where(data[:, index] <= t)
    right = np.where(data[:, index] > t)

    true_data = data[left]
    false_data = data[right]
    true_labels = labels[left]
    false_labels = labels[right]

    return true_data, false_data, true_labels, false_labels
```

In [9]:

```python
# Нахождение наилучшего разбиения

def find_best_split(data, labels):

    #  обозначим минимальное количество объектов в узле
    min_leaf = 5

    current_gini = gini(labels)

    best_quality = 0
    best_t = None
    best_index = None

    n_features = data.shape[1]

    for index in range(n_features):
        # будем проверять только уникальные значения признака, исключая повторения
        t_values = np.unique([row[index] for row in data])

        for t in t_values:
            true_data, false_data, true_labels, false_labels = split(data, labels, inde

        #  пропускаем разбиения, в которых в узле остается менее 5 объектов
            if len(true_data) < min_leaf or len(false_data) < min_leaf:
                continue

            current_quality = quality(true_labels, false_labels, current_gini)

            #  выбираем порог, на котором получается максимальный прирост качества
            if current_quality > best_quality:
                best_quality, best_t, best_index = current_quality, t, index

    return best_quality, best_t, best_index
```

In [10]:

```python
def classify_object(obj, node):

    #  Останавливаем рекурсию, если достигли листа
    if isinstance(node, Leaf):
        answer = node.prediction
        return answer

    if obj[node.index] <= node.t:
        return classify_object(obj, node.true_branch)
    else:
        return classify_object(obj, node.false_branch)
```

In [11]:

```python
def predict(data, tree):

    classes = []
    for obj in data:
        prediction = classify_object(obj, tree)
        classes.append(prediction)
    return classes
```

Органичим глубину дерева

In [13]:

```python
d = int(input("Введите максимальную глубину дерева: "))

# Построение дерева с помощью рекурсивной функции
def build_tree(data, labels):
    global depth, true_branch, false_branch
    print("Глубина", depth)
    quality, t, index = find_best_split(data, labels)

#       Базовый случай - прекращаем рекурсию, когда нет прироста в качества
    if quality == 0:
        return Leaf(data, labels)
        print("quality == 0")

    if depth == d:
        return Leaf(data, labels)

    # Рекурсивно строим два поддерева
    print("Делаем ветвление на глубине ", depth)
    depth += 1
    true_data, false_data, true_labels, false_labels = split(data, labels, index, t)
    true_branch = build_tree(true_data, true_labels)
    false_branch = build_tree(false_data, false_labels)

    # Возвращаем класс узла со всеми поддеревьями, то есть целого дерева
    return Node(index, t, true_branch, false_branch)
```

```
Введите максимальную глубину дерева: 5
```

In [14]:

```
# Построим дерево по обучающей выборке
depth = 0
true_branch = None
false_branch = None
my_tree = build_tree(train_data, train_labels)
```

```
Глубина 0
Делаем ветвление на глубине  0
Глубина 1
Делаем ветвление на глубине  1
Глубина 2
Делаем ветвление на глубине  2
Глубина 3
Делаем ветвление на глубине  3
Глубина 4
Делаем ветвление на глубине  4
Глубина 5
Глубина 5
Глубина 5
Глубина 5
Глубина 5
Глубина 5
```

In [15]:

```python
# Напечатаем ход нашего дерева
def print_tree(node, spacing=""):

    # Если лист, то выводим его прогноз
    if isinstance(node, Leaf):
        print(spacing + "Прогноз:", node.prediction)
        return

    # Выведем значение индекса и порога на этом узле
    print(spacing + 'Индекс', str(node.index))
    print(spacing + 'Порог', str(node.t))

    # Рекурсионный вызов функции на положительном поддереве
    print (spacing + '--> True:')
    print_tree(node.true_branch, spacing + "  ")

    # Рекурсионный вызов функции на отрицательном поддереве
    print (spacing + '--> False:')
    print_tree(node.false_branch, spacing + "  ")

print_tree(my_tree)
```

```
Индекс 1
Порог -0.107726691940364
--> True:
  Индекс 1
  Порог -0.3549877301133244
  --> True:
    Индекс 0
    Порог -0.23882214445115557
    --> True:
      Индекс 0
      Порог -0.4381064214473833
      --> True:
        Индекс 0
        Порог -1.793845443769914
        --> True:
          Прогноз: 0
        --> False:
          Прогноз: 0
      --> False:
        Прогноз: 1
    --> False:
      Прогноз: 0
  --> False:
    Прогноз: 0
--> False:
  Прогноз: 1
```

In [16]:

```python
# Получим ответы для обучающей выборки
train_answers = predict(train_data, my_tree)

# Получим ответы для тестовой выборки
test_answers = predict(test_data, my_tree)
```

In [17]:

```python
# Введем функцию подсчета точности как доли правильных ответов
def accuracy_metric(actual, predicted):
    correct = 0
    for i in range(len(actual)):
        if actual[i] == predicted[i]:
            correct += 1
    return correct / float(len(actual)) * 100.0
```

In [18]:

```python
# Точность на обучающей выборке
train_accuracy = accuracy_metric(train_labels, train_answers)
train_accuracy
```

Out[18]:

```
91.71428571428571
```

In [19]:

```python
# Точность на тестовой выборке
test_accuracy = accuracy_metric(test_labels, test_answers)
test_accuracy
```

Out[19]:

```
89.33333333333333
```

In [20]:

```
# Визуализируем дерево на графике

def get_meshgrid(data, step=.05, border=1.2):
    x_min, x_max = data[:, 0].min() - border, data[:, 0].max() + border
    y_min, y_max = data[:, 1].min() - border, data[:, 1].max() + border
    return np.meshgrid(np.arange(x_min, x_max, step), np.arange(y_min, y_max, step))

plt.figure(figsize = (16, 7))

# график обучающей выборки
plt.subplot(1,2,1)
xx, yy = get_meshgrid(train_data)
mesh_predictions = np.array(predict(np.c_[xx.ravel(), yy.ravel()], my_tree)).reshape(x
plt.pcolormesh(xx, yy, mesh_predictions, cmap = light_colors)
plt.scatter(train_data[:, 0], train_data[:, 1], c = train_labels, cmap = colors)
plt.title(f'Train accuracy={train_accuracy:.2f}')

# график тестовой выборки
plt.subplot(1,2,2)
plt.pcolormesh(xx, yy, mesh_predictions, cmap = light_colors)
plt.scatter(test_data[:, 0], test_data[:, 1], c = test_labels, cmap = colors)
plt.title(f'Test accuracy={test_accuracy:.2f}')
```

Out[20]:

```
Text(0.5, 1.0, 'Test accuracy=89.33')
```

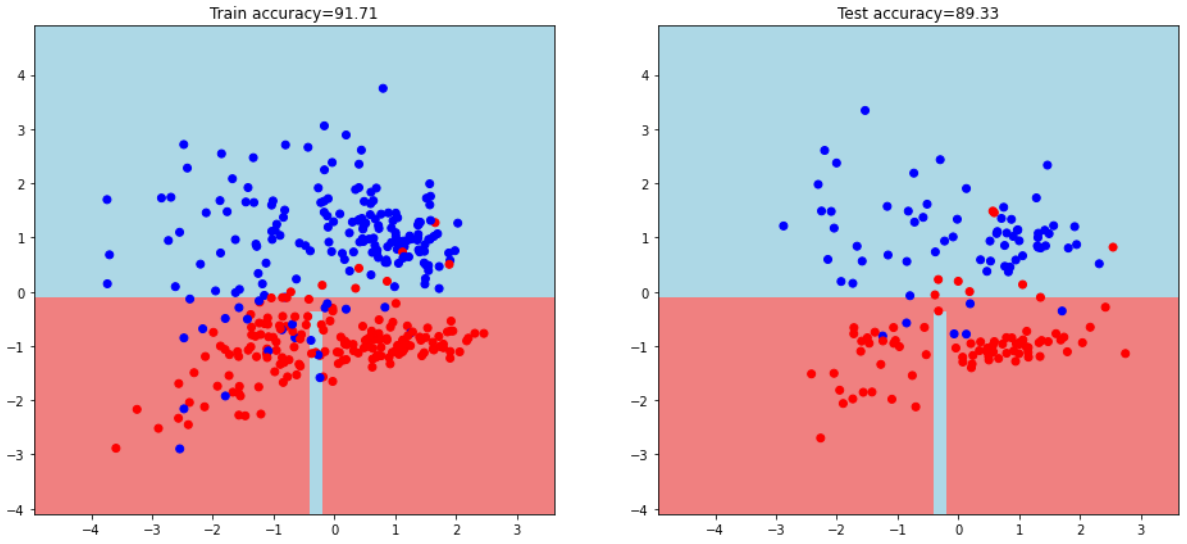

2. Для задачи классификации обучите дерево решений с использованием критериев разбиения Джини и Энтропия. Сравните качество классификации, сделайте выводы.

In [21]:

```python
# Расчет критерия энтропия

def entropy(labels):
    #  подсчет количества объектов разных классов
    classes = {}
    for label in labels:
        if label not in classes:
            classes[label] = 0
        classes[label] += 1

    #  расчет критерия
    impurity = 1 # коэффициент неопределенности энтропии
    for label in classes:
        p = classes[label] / len(labels)
        impurity -= np.sum(p * np.log2(p))

    return impurity
```

Функционал качества:

$$Q = H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r)$$

In [22]:

```python
# Расчет качества

def quality(left_labels, right_labels, current_entropy):

    # доля выбоки, ушедшая в левое поддерево
    p = float(left_labels.shape[0]) / (left_labels.shape[0] + right_labels.shape[0])

    return current_entropy - p * entropy(left_labels) - (1 - p) * entropy(right_labels)
```

In [23]:

```python
# Разбиение датасета в узле

def split(data, labels, index, t):
    left = np.where(data[:, index] <= t)
    right = np.where(data[:, index] > t)

    true_data = data[left]
    false_data = data[right]
    true_labels = labels[left]
    false_labels = labels[right]

    return true_data, false_data, true_labels, false_labels
```

In [24]:

```python
# Нахождение наилучшего разбиения

def find_best_split(data, labels):

    #  обозначим минимальное количество объектов в узле
    min_leaf = 5

    current_entropy = entropy(labels)

    best_quality = 0
    best_t = None
    best_index = None

    n_features = data.shape[1]

    for index in range(n_features):
        # будем проверять только уникальные значения признака, исключая повторения
        t_values = np.unique([row[index] for row in data])

        for t in t_values:
            true_data, false_data, true_labels, false_labels = split(data, labels, inde

        #  пропускаем разбиения, в которых в узле остается менее 5 объектов
            if len(true_data) < min_leaf or len(false_data) < min_leaf:
                continue

            current_quality = quality(true_labels, false_labels, current_entropy)

            #  выбираем порог, на котором получается максимальный прирост качества
            if current_quality > best_quality:
                best_quality, best_t, best_index = current_quality, t, index

    return best_quality, best_t, best_index
```

In [25]:

```python
def classify_object(obj, node):

    #  Останавливаем рекурсию, если достигли листа
    if isinstance(node, Leaf):
        answer = node.prediction
        return answer

    if obj[node.index] <= node.t:
        return classify_object(obj, node.true_branch)
    else:
        return classify_object(obj, node.false_branch)
```

In [26]:

```python
def predict(data, tree):

    classes = []
    for obj in data:
        prediction = classify_object(obj, tree)
        classes.append(prediction)
    return classes
```

Органичим глубину дерева

In [27]:

```python
d = int(input("Введите максимальную глубину дерева: "))

# Построение дерева с помощью рекурсивной функции
def build_tree(data, labels):
    global depth, true_branch, false_branch
    print("Глубина", depth)
    quality, t, index = find_best_split(data, labels)

#       Базовый случай - прекращаем рекурсию, когда нет прироста в качества
    if quality == 0:
        return Leaf(data, labels)
        print("quality == 0")

    if depth == d:
        return Leaf(data, labels)

    # Рекурсивно строим два поддерева
    print("Делаем ветвление на глубине ", depth)
    depth += 1
    true_data, false_data, true_labels, false_labels = split(data, labels, index, t)
    true_branch = build_tree(true_data, true_labels)
    false_branch = build_tree(false_data, false_labels)

    # Возвращаем класс узла со всеми поддеревьями, то есть целого дерева
    return Node(index, t, true_branch, false_branch)
```

```
Введите максимальную глубину дерева: 5
```

In [28]:

```python
# Построим дерево по обучающей выборке
depth = 0
true_branch = None
false_branch = None
my_tree = build_tree(train_data, train_labels)
```

```
Глубина 0
Делаем ветвление на глубине  0
Глубина 1
Делаем ветвление на глубине  1
Глубина 2
Делаем ветвление на глубине  2
Глубина 3
Делаем ветвление на глубине  3
Глубина 4
Делаем ветвление на глубине  4
Глубина 5
Глубина 5
Глубина 5
Глубина 5
Глубина 5
Глубина 5
```

In [29]:

```python
# Напечатаем ход нашего дерева
def print_tree(node, spacing=""):

    # Если лист, то выводим его прогноз
    if isinstance(node, Leaf):
        print(spacing + "Прогноз:", node.prediction)
        return

    # Выведем значение индекса и порога на этом узле
    print(spacing + 'Индекс', str(node.index))
    print(spacing + 'Порог', str(node.t))

    # Рекурсионный вызов функции на положительном поддереве
    print (spacing + '--> True:')
    print_tree(node.true_branch, spacing + "  ")

    # Рекурсионный вызов функции на отрицательном поддереве
    print (spacing + '--> False:')
    print_tree(node.false_branch, spacing + "  ")

print_tree(my_tree)
```

```
Индекс 1
Порог -0.107726691940364
--> True:
  Индекс 1
  Порог -0.5175343065438042
  --> True:
    Индекс 0
    Порог -0.23882214445115557
    --> True:
      Индекс 0
      Порог -0.46469463939970623
      --> True:
        Индекс 0
        Порог -2.165676399540467
        --> True:
          Прогноз: 0
        --> False:
          Прогноз: 0
      --> False:
        Прогноз: 1
    --> False:
      Прогноз: 0
  --> False:
    Прогноз: 0
--> False:
  Прогноз: 1
```

In [30]:

```python
# Получим ответы для обучающей выборки
train_answers = predict(train_data, my_tree)

# Получим ответы для тестовой выборки
test_answers = predict(test_data, my_tree)
```

In [31]:

```python
# Введем функцию подсчета точности как доли правильных ответов
def accuracy_metric(actual, predicted):
    correct = 0
    for i in range(len(actual)):
        if actual[i] == predicted[i]:
            correct += 1
    return correct / float(len(actual)) * 100.0
```

In [32]:

```python
# Точность на обучающей выборке
train_accuracy = accuracy_metric(train_labels, train_answers)
train_accuracy
```

Out[32]:

```
91.71428571428571
```

In [33]:

```python
# Точность на тестовой выборке
test_accuracy = accuracy_metric(test_labels, test_answers)
test_accuracy
```

Out[33]:

```
90.0
```

In [34]:

```
# Визуализируем дерево на графике

def get_meshgrid(data, step=.05, border=1.2):
    x_min, x_max = data[:, 0].min() - border, data[:, 0].max() + border
    y_min, y_max = data[:, 1].min() - border, data[:, 1].max() + border
    return np.meshgrid(np.arange(x_min, x_max, step), np.arange(y_min, y_max, step))

plt.figure(figsize = (16, 7))

# график обучающей выборки
plt.subplot(1,2,1)
xx, yy = get_meshgrid(train_data)
mesh_predictions = np.array(predict(np.c_[xx.ravel(), yy.ravel()], my_tree)).reshape(x
plt.pcolormesh(xx, yy, mesh_predictions, cmap = light_colors)
plt.scatter(train_data[:, 0], train_data[:, 1], c = train_labels, cmap = colors)
plt.title(f'Train accuracy={train_accuracy:.2f}')

# график тестовой выборки
plt.subplot(1,2,2)
plt.pcolormesh(xx, yy, mesh_predictions, cmap = light_colors)
plt.scatter(test_data[:, 0], test_data[:, 1], c = test_labels, cmap = colors)
plt.title(f'Test accuracy={test_accuracy:.2f}')
```

Out[34]:

```
Text(0.5, 1.0, 'Test accuracy=90.00')
```

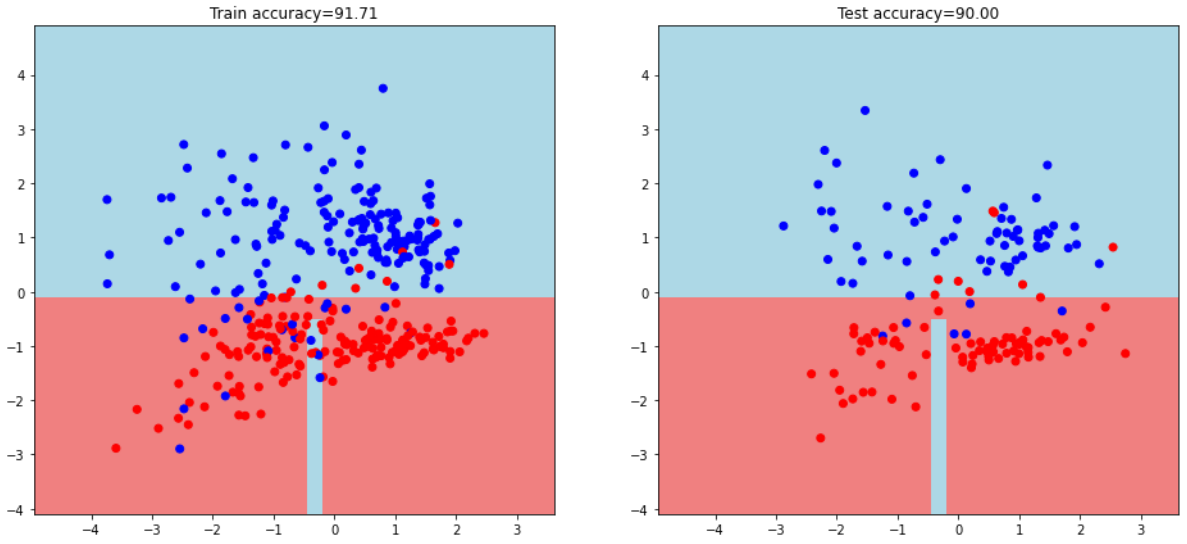

Вывод: Видим, что качество работы моделей на этих данных идентичное

3. *Реализуйте дерево для задачи регрессии. Возьмите за основу дерево, реализованное в методичке, заменив механизм предсказания в листе на взятие среднего значения по выборке, а критерий Джини на дисперсию значений.

Сгенерируем датасет для регрессии

In [35]:

```
from sklearn.datasets import load_boston
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
from sklearn.model_selection import learning_curve
from sklearn.metrics import make_scorer
%matplotlib inline

np.random.seed(42)

boston_data = load_boston()
boston_df = pd.DataFrame(boston_data.data, columns=boston_data.feature_names)
boston_df_2 = pd.DataFrame(boston_data.data, columns=boston_data.feature_names)
# boston_df = np.array(boston_df[['RM', 'LSTAT']])
```

```
C:\ProgramData\Anaconda3\lib\site-packages\statsmodels\tools\_testing.py:19:
FutureWarning: pandas.util.testing is deprecated. Use the functions in the pu
blic API at pandas.testing instead.
  import pandas.util.testing as tm
```

In [36]:

```
boston_df
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33
...	...	...	...	...	...	...	...	...	...	...	...	...	...
501	0.06263	0.0	11.93	0.0	0.573	6.593	69.1	2.4786	1.0	273.0	21.0	391.99	9.67
502	0.04527	0.0	11.93	0.0	0.573	6.120	76.7	2.2875	1.0	273.0	21.0	396.90	9.08
503	0.06076	0.0	11.93	0.0	0.573	6.976	91.0	2.1675	1.0	273.0	21.0	396.90	5.64
504	0.10959	0.0	11.93	0.0	0.573	6.794	89.3	2.3889	1.0	273.0	21.0	393.45	6.48
505	0.04741	0.0	11.93	0.0	0.573	6.030	80.8	2.5050	1.0	273.0	21.0	396.90	7.88

Переведем таблицу в матрицу

In [37]:

```
boston_df = np.array(boston_df)
target = boston_data.target
```

In [38]:

```
# И класс терминального узла (листа)

class Leaf:

    def __init__(self, data, labels):
        self.data = data
        self.labels = labels
        self.prediction = self.predict()

    def predict(self):
        prediction = np.mean(self.labels)
        return prediction
```

In [39]:

```
#перемешаем данные
np.random.seed(41)
shuffle_index = np.random.permutation(boston_df.shape[0])
X_shuffled, y_shuffled = boston_df[shuffle_index], np.array(target[shuffle_index])

```

In [40]:

```
# разбивка на обучающую и тестовую выборки
train_proportion = 0.7
train_test_cut = int(len(classes[0]) * train_proportion)

train_data, test_data, train_labels, test_labels = \
    X_shuffled[:train_test_cut], \
    X_shuffled[train_test_cut:], \
    y_shuffled[:train_test_cut], \
    y_shuffled[train_test_cut:]
```

В случае регрессии разброс будет характеризоваться дисперсией, поэтому критерий информативности будет записан в виде

$$H(X) = \frac{1}{X}\sum_{i \in X}(y_i - \bar{y}(X))^2,$$

где $\bar{y}(X)$ - среднее значение ответа в выборке X:

$$\bar{y}(X) = \frac{1}{|X|}\sum_{i \in X} y_i.$$

In [41]:

```
# Расчет дисперсии
def variance(labels):

    impurity = (np.sum())/labels
    return impurity
```

In [42]:

```
# Расчет дисперсии

def variance(labels):

    impurity = np.var(labels)
    return impurity
```

In [43]:

```
# Расчет качества

def quality(left_labels, right_labels, current_variance):

    # доля выбоки, ушедшая в левое поддерево
    p = float(left_labels.shape[0]) / (left_labels.shape[0] + right_labels.shape[0])

    return current_variance - p * variance(left_labels) - (1 - p) * variance(right_labe
```

In [44]:

```
# Разбиение датасета в узле

def split(data, labels, index, t):
    left = np.where(data[:, index] <= t)
    right = np.where(data[:, index] > t)

    true_data = data[left]
    false_data = data[right]
    true_labels = labels[left]
    false_labels = labels[right]

    return true_data, false_data, true_labels, false_labels
```

In [45]:

```
# Нахождение наилучшего разбиения

def find_best_split(data, labels):

    #  обозначим минимальное количество объектов в узле
    min_leaf = 5

    current_variance = variance(labels)

    best_quality = 0
    best_t = None
    best_index = None

    n_features = data.shape[1]

    for index in range(n_features):
        # будем проверять только уникальные значения признака, исключая повторения
        t_values = np.unique([row[index] for row in data])

        for t in t_values:
            true_data, false_data, true_labels, false_labels = split(data, labels, inde

        #  пропускаем разбиения, в которых в узле остается менее 5 объектов
            if len(true_data) < min_leaf or len(false_data) < min_leaf:
                continue

            current_quality = quality(true_labels, false_labels, current_variance)

            #  выбираем порог, на котором получается максимальный прирост качества
            if current_quality > best_quality:
                best_quality, best_t, best_index = current_quality, t, index

    return best_quality, best_t, best_index
```

In [46]:

```
def classify_object(obj, node):

    #  Останавливаем рекурсию, если достигли листа
    if isinstance(node, Leaf):
        answer = node.prediction
        return answer

    if obj[node.index] <= node.t:
        return classify_object(obj, node.true_branch)
    else:
        return classify_object(obj, node.false_branch)
```

In [47]:

```
def predict(data, tree):

    classes = []
    for obj in data:
        prediction = classify_object(obj, tree)
        classes.append(prediction)
    return classes
```

Органичим глубину дерева

In [48]:

```python
d = int(input("Введите максимальную глубину дерева: "))

# Построение дерева с помощью рекурсивной функции
def build_tree(data, labels):
    global depth, true_branch, false_branch
    print("Глубина", depth)
    quality, t, index = find_best_split(data, labels)

#      Базовый случай - прекращаем рекурсию, когда нет прироста в качества
    if quality == 0:
        return Leaf(data, labels)
        print("quality == 0")

    if depth == d:
        return Leaf(data, labels)

    # Рекурсивно строим два поддерева
    print("Делаем ветвление на глубине ", depth)
    depth += 1
    true_data, false_data, true_labels, false_labels = split(data, labels, index, t)
    true_branch = build_tree(true_data, true_labels)
    false_branch = build_tree(false_data, false_labels)

    # Возвращаем класс узла со всеми поддеревьями, то есть целого дерева
    return Node(index, t, true_branch, false_branch)
```

```
Введите максимальную глубину дерева: 5
```

In [49]:

```python
# Построим дерево по обучающей выборке
depth = 0
true_branch = None
false_branch = None
my_tree = build_tree(train_data, train_labels)
```

```
Глубина 0
Делаем ветвление на глубине  0
Глубина 1
Делаем ветвление на глубине  1
Глубина 2
Делаем ветвление на глубине  2
Глубина 3
Глубина 3
Делаем ветвление на глубине  3
Глубина 4
Делаем ветвление на глубине  4
Глубина 5
Глубина 5
Глубина 5
Глубина 5
Глубина 5
```

In [50]:

```python
# Напечатаем ход нашего дерева
def print_tree(node, spacing=""):

    # Если лист, то выводим его прогноз
    if isinstance(node, Leaf):
        print(spacing + "Прогноз:", node.prediction)
        return

    # Выведем значение индекса и порога на этом узле
    print(spacing + 'Индекс', str(node.index))
    print(spacing + 'Порог', str(node.t))

    # Рекурсионный вызов функции на положительном поддереве
    print (spacing + '--> True:')
    print_tree(node.true_branch, spacing + "  ")

    # Рекурсионный вызов функции на отрицательном поддереве
    print (spacing + '--> False:')
    print_tree(node.false_branch, spacing + "  ")

print_tree(my_tree)
```

```
Индекс 12
Порог 9.53
--> True:
  Индекс 5
  Порог 7.42
  --> True:
    Индекс 7
    Порог 1.7573
    --> True:
      Индекс 5
      Порог 6.538
      --> True:
        Прогноз: 22.87068965517241
      --> False:
        Прогноз: 27.54
    --> False:
      Индекс 5
      Порог 6.794
      --> True:
        Индекс 5
        Порог 6.538
        --> True:
          Прогноз: 22.87068965517241
        --> False:
          Прогноз: 27.54
      --> False:
        Прогноз: 32.768571428571434
  --> False:
    Прогноз: 44.915
--> False:
  Прогноз: 17.74455445544554
```

In [51]:

```
# Получим ответы для обучающей выборки
train_answers = predict(train_data, my_tree)

# Получим ответы для тестовой выборки
test_answers = predict(test_data, my_tree)
```

In [52]:

```
from sklearn.metrics import mean_absolute_error
```

In [53]:

```
# Точность на обучающей выборке
mean_absolute_error(train_labels, train_answers)
```

Out[53]:

```
3.6628201238843094
```

In [54]:

```
# Точность на тестовой выборке
mean_absolute_error(test_labels, test_answers)
```

Out[54]:

```
3.911579368622728
```